

TD - Evaluating the carbon footprint of an AI program

Mathieu WAHARTE

12/03/2026


1. Carbon footprint of a machine learning program

1) Pour 8 Xeon E5-2683 v4 et 5 Tesla V100 ayant 32Go de mémoire, on calcule l'empreinte carbone de 210 heures de calculs à Orsay avec [l'algorithme de Green](#).

Le nombre total de coeurs utilisés est $8 \times |Xeon|_{cores} = 8 \times 16 = 128$ coeurs ([Référence](#))

La taille totale de mémoire utilisée est $5 \times 32 = 160$ Go


Donc en donnant tout ces détails au calculateur, on obtient :



2) Avec un PUE de 1.2 au lieu de 1.67 on a :

Do you know the Power Usage Efficiency (PUE) of your local data centre?

☒ Yes ☐ No ⓘ




Notre énergie utilisée et notre empreinte carbone ont toutes deux baissé de 23.1%. C'est le même taux pour les deux car le PUE mesure l'efficacité électrique, donc toutes les "économies" carbonées proviennent de la réduction en électricité utilisée.

3) Comme le rafraîchissement occupe une part importante de la consommation totale (quasiment autant que les équipements mêmes), un PUE moyen calculé sur les équipements pose certains [problèmes](#) :

- Il masque les variabilités saisonnières de la consommation du datacenter, par exemple on consommera plus en été pour le refroidissement
- Il ne tient pas en compte de la géographie, un datacenter en antarctique consomme moins au global qu'en Equateur
- Il ne tient pas en compte de l'usage réel de l'équipement. En effet, si l'équipement est peu utilisé, alors le coût du refroidissement sera plus faible et le PUE pourrait être plus faible qu'un serveur plus efficace mais très utilisé.

4) On va estimer quel pourcentage des usages totaux de la machine physique sont calculés par l'algorithme Green.

Premièrement, dans notre cas, regardons le rapport de consommation entre 1 CPU complet et 1 GPU :




Donc on peut estimer qu'un GPU consomme 3 fois plus d'énergie que le CPU (car la formule entre énergie et carbone est purement multiplicative sans mémoire donc les rapports sont conservés).

Ainsi, si on veut estimer le pourcentage de la consommation du GPU dans la machine physique, on peut recalculer le pie-chart.

Le CPU prend actuellement 43% de la consommation, comme l'usage est relatif, on peut dire qu'il prend 43 parts d'un total de 100 parts. Ainsi le GPU prendrais $43 \times 3 = 129$ parts. Sauf que le total n'est plus le même en ajoutant le GPU, il devient de 229 parts. Calculons les parts de chaque élément :

- GPU : $(129 / 229) * 100 = 56.3\%$
- CPU : $(43 / 229) * 100 = 18.8\%$
- Peripheral: $(17 / 229) * 100 = 7.4\%$
- Other: $(16 / 229) * 100 = 7.0\%$
- Memory: $(12 / 229) * 100 = 5.2\%$
- Motherboard: $(8 / 229) * 100 = 3.5\%$
- Disk: $(4 / 229) * 100 = 1.8\%$

Voici les 2 graphes côte à côte:



L'algorithme de Green ne parle que du CPU, GPU et de la mémoire, en sommant les contributions, il explique donc $56.3 + 18.8 + 5.2 = 80.3\%$ de la consommation totale du système.

5) Utiliser ce site web est un moyen bien plus simple et rapide d'estimer l'empreinte carbone de son algorithme. Il est accessible sur le web, n'as que quelques paramètres rapides à remplir et simple à obtenir ou estimer et est transparent dans sa méthode. En revanche, il ne permet pas d'avoir la consommation/les émissions réelles et d'identifier leur sources.

2. Taking into account the life cycle of equipment

1) L'algorithme Green ne calcule que l'empreinte carbone opérationnelle (électricité) des serveurs de calcul. Ce qui, d'après le tableau 2 correspond à seulement 45% de l'empreinte carbone totale du data center.

2) Pour moi, utiliser un serveur dans le cloud consomme moins de carbone de par les économies d'échelle. En sélectionnant un serveur Azure dans le même pays, on obtient :

Select the platform used for the computations

Cloud computing

Azure

Select server

Europe

France Central



30.39 kgCO_{2e}
Carbon footprint



592.61 kWh
Energy needed

On consomme donc bien moins de carbone sur le cloud (pour le même pays).



42.33kgCO_{2e} en local VS 30.39kgCO_{2e} en cloud => 28.2% de réduction

852.42kWh en local VS 592.61kWh en cloud => 30.5% de réduction



3) La comparaison entre local et cloud est insuffisante ici. En effet, ce simulateur prend en compte moins de la moitié du coût carbone réel des serveurs (tableau 2), un serveur cloud remplace probablement son équipement bien plus fréquemment qu'un serveur local, ce qui a un impact majeur non calculé. Aussi, ce simulateur utilise le PUE global du serveur qu'on a prouvé comme étant insuffisant.

4) Comparons la consommation de plusieurs générations de GPU :



- (Base) V100 :



- (Ancien) P100 :



- (Récent) TPU v4 :




On observe 2 tendances:

- le matériel spécialisé est plus efficace (d'où le développement d'ASICs pour l'inférence IA)
- le matériel plus ancien semble moins consommer

5) Pour inclure le coût de fabrication en carbone dans le calcul, il nous faut le facteur d'émission de fabrication de chaque équipement mais aussi leur durée de vie utile ainsi que la fréquence de remplacement du matériel. En effet, un composant bas carbone mais de faible durée de vie peut être pire qu'un plus coûteux en carbone mais qui dure plus longtemps. La fréquence de remplacement du matériel pourrait inverser la tendance d'économie en carbone à faire les calculs sur le cloud.

3. Carbon footprint / accuracy trade-of

1) Considérons un scénario comme à la question 1) de la partie 1 mais où l'on arrête l'entraînement après 72h (3 jours) au lieu de 210h. On obtient alors :



On passe de 42.33kgCO_{2e} à 14.51kgCO_{2e}, soit une réduction de 66% proportionnelle à la réduction en temps d'entraînement. On peut se demander quel pourcentage du résultat est obtenu à cette étape et si ça vaut le coût de continuer.

2) Sur la figure 2, les gains entre 50 et 100% de l'émissions en CO₂ sont de 2.67% sur CommonVoice et 0.37% sur LibriSpeech.

Il est compliqué de pointer à une métrique précise pour déterminer à quel moment il est raisonnable de s'arrêter. Intuitivement, on veut s'arrêter quand l'exponentielle en usage carbone/ amélioration commence à exploser. Pour LibriSpeech on pourrait s'arrêter quand le WER atteint 5% puisque c'est le début de cette croissance mais si on applique le même raisonnement sur CommonVoice, comme la croissance est un peu plus lente, on s'arrêterait avec un WER de 30% environ pour moins de 20% du CO₂ environ alors qu'avec "seulement" 20% du CO₂ total en plus, on atteint un WER de 20%.

Donc l'heuristique, de s'arrêter au point d'inflexion est bonne mais il serait intéressant d'y rajouter une évaluation de l'amélioration relative en performance comparé au coût additionnel estimé en CO₂.

4. Training vs inference

1) Pour appliquer le PSF (Power Scaling Factor) de 2, on va multiplier par 2 les GPUs.
On a 832 Nvidia A100 80Go effectifs. On néglige les impacts CPU et mémoire comme suggéré.
Pour un PUE de 1.2 et le serveur en France, les émissions sur la durée totale sont de :

TRAINING	INFERENCE
Report your training-related computations. For more information about R&D experiments, retraining or overall tips regarding your reporting, please refer to the Help tab. Runtime (HH:MM) 2837 41 Type of cores GPU Number of GPUs 832 Model NVIDIA A100 80GB PCIe Memory available (in GB) 33280 Select the platform used for the computations Local server Select location Europe France Do you know the real usage factor of your GPU? ☐ Yes ☒ No Do you know the Power Usage Efficiency (PUE) of your local data centre? ☒ Yes ☐ No 1.2 R&D TRAINING Do you want to add R&D compute time? ☐ Yes ☒ No RETRAINING Do you want to add retraining compute time? ☐ Yes ☒ No	Report your inference-related computations. For more information about continuous inference or overall tips regarding your reporting, please refer to the Help tab. ☐ Apply continuous inference scheme Runtime (HH:MM) 0 0 Type of cores CPU Number of cores 0 Model Xeon E5-2683 v4 Memory available (in GB) 0 Select the platform used for the computations Local server Select location Europe Austria Do you know the real usage factor of your CPU? ☐ Yes ☒ No Do you know the Power Usage Efficiency (PUE) of your local data centre? ☐ Yes ☒ No Do you want to use a multiplicative factor? ☐ Yes ☒ No
 45.75 TCO_{2e} Carbon footprint Training: 45.75 TCO_{2e} Inference: 0.00 mgCO_{2e}	 892.16 MWh Energy needed Training: 892.16 MWh Inference: 0.00 Wh

L'empreinte carbone de l'entraînement est donc de 45.75TCO_{2e}.


2) L'empreinte carbone de l'inférence est $118 \times 19 = 2.24 \text{TCO}_2\text{e}$.

L'entraînement coûte 20.4 plus cher que l'inférence en termes de CO_2 pour environ le même temps. Il faut donc éviter d'entraîner souvent des modèles.


5. Green or carbon-less electricity?

1) Testons d'autres emplacements de serveurs :


- Pologne:



- Suède :



Et la France produisant 45.75TCO_{2e} pour le même entraînement.



Comme on s'y attend, la Pologne qui utilise une électricité très intense en carbone produit bien plus que le serveur en France tandis que la Suède qui as une énergie quasiment complètement propre (là on n'a mis qu'une de ses régions) en produit encore moins que la France qui comble un peu sa production nucléaire avec des énergies plus carbonées.

2) L'achat d'énergies renouvelables par Google est bien mais ne réduit pas l'impact à zéro. En effet, cet effect annuel ne garanti pas un approvisionnement temporaire carboné mais aussi, Google peut acheter ces énergies dans une région afin de compenser une consommation très carbonnée dans une autre région. De plus, comme on l'as vu, cela ne prends pas en compte l'impact carbone de la fabrication (et recyclage) du matériel même et non juste son utilisation.